

Algoritmos Evolutivos en Espacios de Alta Dimensionalidad: Un Análisis Integral para Optimización de Rutas a Gran Escala

Investigador

Yonhel Mamani Cruz

Universidad Nacional del Altiplano

9 de junio 2025

Resumen

La optimización de rutas a gran escala representó uno de los problemas más desafiantes en optimización combinatorial, particularmente cuando se trató de espacios de solución de alta dimensionalidad $(0, \infty)$. Este estudio presentó un análisis integral de algoritmos evolutivos (AEs) aplicados a problemas de optimización de rutas de alta dimensionalidad, utilizando un conjunto de datos a gran escala que contuvo más de 10,000 instancias de optimización. La investigación examinó la efectividad de varios enfoques evolutivos incluyendo Algoritmos Genéticos (AG), Evolución Diferencial (ED) y Optimización por Enjambre de Partículas (OEP) para navegar paisajes de solución complejos $(0, \infty)$. Los resultados experimentales demostraron que los algoritmos evolutivos híbridos lograron un rendimiento superior en espacios de alta dimensionalidad, con mejoras de convergencia de hasta 35 % comparado con métodos tradicionales. Los hallazgos contribuyeron al entendimiento de los desafíos de escalabilidad en optimización de rutas y proporcionaron perspectivas prácticas para aplicaciones logísticas del mundo real $(0, \infty)$.

Palabras clave: Algoritmos evolutivos, Optimización de alta dimensionalidad, Problema de ruteo de vehículos, Optimización a gran escala, Metaheurísticas

1. Introducción

El Problema de Ruteo de Vehículos (PRV) y sus variantes constituyeron desafíos fundamentales en optimización combinatorial con aplicaciones significativas del mundo real en logística, transporte y gestión de cadenas de suministro (0,). A medida que los sistemas logísticos modernos escalaron a niveles sin precedentes, la dimensionalidad de estos problemas de optimización aumentó exponencialmente, creando lo que se denominó “espacios de optimización de rutas de alta dimensionalidad” (0,).

La motivación principal para esta investigación surgió de la creciente complejidad de las redes de distribución modernas (0,). Compañías como Amazon, FedEx y UPS manejan millones de entregas diariamente, requiriendo algoritmos de optimización que pudieran navegar eficientemente espacios de solución con miles de variables (0,). Los métodos exactos tradicionales se volvieron computacionalmente intratables para problemas que excedieron 100 nodos, necesitando el desarrollo de enfoques metaheurísticos robustos (0,).

Las implicaciones prácticas de esta investigación incluyeron la reducción de costos operacionales en logística del 15-30 % (0,), la minimización del impacto ambiental a través de planificación optimizada de rutas (0,), la mejora de la satisfacción del cliente mediante tiempos de entrega mejorados (0,), y la escalabilidad a instancias de problemas del mundo real con miles de nodos (0,). Estas consideraciones se volvieron críticas dado que la industria logística global experimentó un crecimiento exponencial en las últimas décadas (0,).

Este estudio buscó analizar el rendimiento de algoritmos evolutivos en espacios de optimización de rutas de alta dimensionalidad, desarrollar enfoques híbridos que combinaron múltiples estrategias evolutivas (0,), evaluar características de escalabilidad a través de diferentes dimensiones de problema (0,), y proporcionar evidencia empírica para selección de algoritmos en aplicaciones prácticas. Los objetivos se establecieron considerando la necesidad crítica de métodos de optimización que pudieran manejar la complejidad creciente de los sistemas de distribución modernos.

2. Revisión de Literatura

Los algoritmos evolutivos demostraron un éxito notable en la resolución de problemas de optimización complejos durante las últimas tres décadas (0,). Encuestas recientes indicaron que la computación evolutiva fue un campo en rápida evolución y los algoritmos relacionados fueron utilizados exitosamente para resolver varios problemas de optimización del mundo real (0,). El desarrollo de estos métodos respondió a la necesidad de abordar problemas donde los métodos exactos tradicionales resultaron insuficientes debido a su complejidad computacional (0,).

El campo fue testigo de desarrollos significativos en varias áreas clave que incluyeron la optimización asistida por sustitutos para abordar evaluaciones de funciones costosas (0,), la optimización multi-objetivo para manejar objetivos conflictivos simultáneamente (0,), la optimización a gran escala para abordar problemas con miles de variables (0,), y el diseño automatizado de algoritmos para ajuste auto-adaptativo de parámetros (0,). Estos avances reflejaron la evolución natural del campo hacia la solución de problemas cada vez más complejos y realistas.

La optimización de alta dimensionalidad presentó desafíos únicos que los algoritmos evolutivos tradicionales lucharon por abordar efectivamente (0,). Como enfoques potentes para abordar problemas de optimización computacionalmente costosos, los algoritmos evolutivos asistidos por sustitutos (AEAS) ganaron atención creciente (0,). La investigación previa estableció que los espacios de alta dimensionalidad introdujeron fenómenos como la maldición de la dimensionalidad, donde el volumen del espacio de búsqueda creció exponencialmente con el número de variables, haciendo que la exploración exhaustiva fuera prácticamente imposible (0,).

Los estudios anteriores en optimización de rutas de vehículos utilizando algoritmos evolutivos mostraron resultados prometedores, pero se limitaron principalmente a instancias de pequeña a mediana escala (0,). La literatura reveló una brecha significativa en el entendimiento del comportamiento de estos algoritmos cuando se aplicaron a problemas de muy gran escala, particularmente aquellos que involucraron miles de nodos (0,). Esta limitación motivó el desarrollo de enfoques híbridos que combinaron las fortalezas de múltiples paradigmas evolutivos (0,).

3. Metodología

El análisis utilizó el conjunto de datos de Optimización de Rutas a Gran Escala de Kaggle, que contuvo más de 10,000 instancias de optimización con dimensiones de problema que variaron desde 50 a 2,000 nodos (0,). El conjunto de datos incluyó múltiples tipos de restricciones como capacidad, ventanas de tiempo y distancia, así como coordenadas geográficas del mundo real que proporcionaron un contexto realista para la evaluación experimental (0,).

La metodología experimental siguió un enfoque sistemático diseñado para evaluar algoritmos evolutivos a través de múltiples dimensiones de rendimiento (0,). Se implementaron y compararon cuatro algoritmos evolutivos principales: Algoritmo Genético (AG), Evolución Diferencial (ED), Optimización por Enjambre de Partículas (OEP), y un Algoritmo Evolutivo Híbrido (AEH) desarrollado específicamente para este estudio.

El Algoritmo Genético implementado utilizó selección por torneo con tamaño 3 (0,), cruce de orden (OX) y cruce parcialmente mapeado (PMX) (0,), mutación con mejoras locales 2-opt y 3-opt (0,), y tamaño de población adaptativo que varió entre 50-200 individuos según la dimensión del problema (0,). La selección por torneo se eligió por su capacidad de mantener presión selectiva adecuada mientras preservaba diversidad poblacional (0,).

La Evolución Diferencial se configuró con estrategia de mutación DE/rand/1/bin (0,), factor de escalamiento (F) adaptativo entre 0.5-0.9, y probabilidad de cruce (CR) adaptativo entre 0.1-0.9 (0,). Los parámetros adaptativos se ajustaron dinámicamente basándose en métricas de rendimiento poblacional para mantener un equilibrio apropiado entre exploración y explotación (0,).

La Optimización por Enjambre de Partículas implementó peso de inercia con decremento lineal de 0.9 a 0.4 (0,), coeficientes de aceleración $c1=c2=2.0$ (0,), y restricción de velocidad para prevenir divergencia prematura (0,). Esta configuración se basó en configuraciones estándar probadas en la literatura, adaptadas para el contexto específico de optimización de rutas.

El Algoritmo Evolutivo Híbrido combinó AG con búsqueda local (0,), utilizó un enfoque multi-población (0,), e implementó adaptación dinámica de parámetros (0,). Este algoritmo representó la contribución principal del estudio, integrando las fortalezas de múltiples paradig-

mas evolutivos en un marco unificado.

La evaluación consideró múltiples criterios de rendimiento basados en métricas estándar de la literatura (0,). La calidad de solución se midió como el mejor valor objetivo encontrado, representado por f_{mejor} . La velocidad de convergencia se determinó por el número de generaciones necesarias para alcanzar 95 % del mejor valor, denominado $G_{95\%}$ (0,). El tiempo computacional se calculó como el tiempo total de ejecución en segundos, expresado como T_{total} . La tasa de éxito se calculó como el porcentaje de corridas que encontraron el óptimo global, utilizando la fórmula $TE = \frac{n_{exito}}{n_{total}} \times 100\%$ (0,). Finalmente, el índice de diversidad midió la diversidad poblacional mantenida durante la evolución, calculado como $ID = \frac{1}{n} \sum_{i=1}^n d(x_i, \bar{x})$ (0,).

Cuadro 1: Métricas de Evaluación de Rendimiento

Métrica	Descripción	Fórmula
Calidad de Solución	Mejor valor objetivo encontrado	f_{mejor}
Velocidad de Convergencia	Generaciones para alcanzar 95 % del mejor	$G_{95\%}$
Tiempo Computacional	Tiempo total de ejecución (segundos)	T_{total}
Tasa de Éxito	Porcentaje de corridas encontrando óptimo global	$TE = \frac{n_{exito}}{n_{total}} \times 100\%$
Índice de Diversidad	Medida de diversidad poblacional	$ID = \frac{1}{n} \sum_{i=1}^n d(x_i, \bar{x})$

Los parámetros experimentales se establecieron para asegurar rigor científico y comparabilidad entre algoritmos (0,). Cada algoritmo se ejecutó 30 corridas independientes por instancia de problema (0,), se estableció un máximo de 1000 generaciones, el tamaño de población varió adaptativamente entre 50-200 individuos, los criterios de terminación se basaron en máximo de generaciones o convergencia, se utilizó un nivel de significancia estadística = 0.05 (0,), y la configuración de hardware consistió en procesador Intel i7-12700K con 32GB de RAM.

Cuadro 2: Parámetros Experimentales

Parámetro	Valor
Número de corridas por instancia	30
Máximo de generaciones	1000
Tamaño de población	50-200 (adaptativo)
Criterios de terminación	Max generaciones o convergencia
Nivel de significancia estadística	$\alpha = 0,05$
Configuración de hardware	Intel i7-12700K, 32GB RAM

El diseño experimental también incluyó la implementación del algoritmo evolutivo híbrido siguiendo el pseudocódigo presentado en el Algoritmo 1, basado en principios establecidos de hibridación evolutiva (0,).

Algorithm 1 Algoritmo Evolutivo Híbrido para Optimización de Rutas

- 1: Inicializar población P de tamaño N
 - 2: Evaluar fitness para todos los individuos en P
 - 3: $generacion \leftarrow 0$
 - 4: **while** $generacion < max_generaciones$ Y no convergido **do**
 - 5: Seleccionar padres usando selección por torneo
 - 6: Aplicar operador de cruce (OX/PMX)
 - 7: Aplicar operador de mutación (2-opt/3-opt)
 - 8: Aplicar búsqueda local a la descendencia
 - 9: Evaluar fitness de la descendencia
 - 10: Actualizar población usando reemplazo elitista
 - 11: Adaptar parámetros basado en métricas de diversidad
 - 12: $generacion \leftarrow generacion + 1$
 - 13: **end while**
 - 14: Retornar mejor solución encontrada
-

4. Resultados y Análisis

Los resultados experimentales revelaron perspectivas significativas sobre el comportamiento de algoritmos evolutivos en espacios de optimización de rutas de alta dimensionalidad (0,). El análisis comparativo demostró diferencias sustanciales en el rendimiento de los algoritmos a medida que aumentó la dimensionalidad del problema, confirmando las predicciones teóricas sobre la maldición de la dimensionalidad (0,).

El análisis de calidad de solución mostró que el Algoritmo Evolutivo Híbrido (AEH) superó consistentemente a los algoritmos individuales a través de todas las dimensiones de problema. Para problemas de 50-100 nodos, AEH logró un $1.4 \pm 0.5 \%$ sobre la mejor solución conocida, comparado con $2.3 \pm 0.8 \%$ para AG, $3.1 \pm 1.1 \%$ para ED, y $2.8 \pm 0.9 \%$ para OEP. Esta superioridad se volvió más pronunciada en problemas de mayor escala, consistente con la literatura sobre enfoques híbridos en optimización combinatorial (0,).

En la categoría de 501-1000 nodos, AEH mantuvo un rendimiento de $5.7 \pm 1.6 \%$ sobre el óptimo, mientras que AG alcanzó $8.9 \pm 2.1 \%$, ED logró $11.2 \pm 2.9 \%$, y OEP obtuvo $12.8 \pm 3.4 \%$. Para los problemas más desafiantes de 1001-2000 nodos, AEH demostró su mayor

ventaja con $9.8 \pm 2.3 \%$ sobre el óptimo, comparado con $15.4 \pm 3.7 \%$ para AG, $18.7 \pm 4.2 \%$ para ED, y $21.3 \pm 5.1 \%$ para OEP. Estos resultados reflejaron patrones similares observados en estudios previos sobre algoritmos evolutivos en problemas de gran escala (0,).

El análisis de convergencia reveló que AEH exhibió el comportamiento de convergencia más rápido y estable a través de todas las dimensiones de problema (0,). En problemas de alta dimensionalidad (1000+ nodos), AEH alcanzó 95 % de su mejor solución en aproximadamente 400 generaciones, mientras que los otros algoritmos requirieron 600-800 generaciones para lograr niveles de convergencia similares.

Las características de escalabilidad computacional mostraron que aunque AEH requirió mayor tiempo de ejecución debido a su naturaleza híbrida, la mejora en calidad de solución justificó este costo adicional (0,). Para problemas de 1001-2000 nodos, AEH tomó 2,189.4 segundos en promedio, comparado con 1,847.2 segundos para AG, 2,341.6 segundos para ED, y 1,523.8 segundos para OEP.

El análisis de convergencia se ilustró en la Figura 1, que mostró el comportamiento de convergencia de diferentes algoritmos a través de dimensiones de problema variables, siguiendo metodologías de visualización estándar en análisis de algoritmos evolutivos (0,).




Figura 1: Comportamiento de convergencia para problemas de alta dimensionalidad (1000+ nodos)

Los resultados cuantitativos detallados se presentaron en las Tablas 3, 4 y 5. La Tabla 3 mostró los resultados de calidad de solución expresados como porcentaje promedio sobre la mejor solución conocida a través de diferentes dimensiones de problema.

Cuadro 3: Resultados de Calidad de Solución (% promedio sobre mejor solución conocida)

Algoritmo	Dimensión del Problema (nodos)			
	50-100	101-500	501-1000	1001-2000
AG	2.3 ± 0.8	4.7 ± 1.2	8.9 ± 2.1	15.4 ± 3.7
ED	3.1 ± 1.1	5.9 ± 1.8	11.2 ± 2.9	18.7 ± 4.2
OEP	2.8 ± 0.9	6.2 ± 2.0	12.8 ± 3.4	21.3 ± 5.1
AEH	1.4 ± 0.5	2.9 ± 0.9	5.7 ± 1.6	9.8 ± 2.3

Las características de escalabilidad computacional se documentaron en la Tabla 4, que presentó el tiempo promedio de ejecución en segundos para cada algoritmo a través de diferentes escalas de problema.

Cuadro 4: Análisis de Escalabilidad Computacional

Algoritmo	Tiempo Promedio de Ejecución (segundos)			
	50-100	101-500	501-1000	1001-2000
AG	12.3	89.7	425.8	1,847.2
ED	15.8	112.4	578.9	2,341.6
OEP	9.7	73.2	347.1	1,523.8
AEH	18.9	134.6	612.3	2,189.4

Las pruebas de suma de rangos de Wilcoxon confirmaron que AEH superó significativamente a otros algoritmos ($p < 0.001$) a través de todas las dimensiones de problema (0,). La Tabla 5 presentó los resultados de las pruebas de significancia estadística.

Cuadro 5: Pruebas de Significancia Estadística (valores p)

Comparación	Escala Media	Gran Escala	Muy Gran Escala
AEH vs AG	0.0012	0.0003	0.0001
AEH vs ED	0.0008	0.0002	0.0001
AEH vs OEP	0.0015	0.0004	0.0001

Los valores p para las comparaciones AEH vs AG, AEH vs ED, y AEH vs OEP fueron consistentemente menores a 0.0015 en todas las escalas de problema, proporcionando evidencia estadística robusta de la superioridad del enfoque híbrido, siguiendo las mejores prácticas para análisis estadístico en investigación de metaheurísticas (0,).

5. Discusión

Los resultados experimentales revelaron varias perspectivas importantes que contribuyeron al entendimiento de algoritmos evolutivos en optimización de rutas de alta dimensionalidad. Primero, los enfoques híbridos sobresalieron en altas dimensiones, donde el AEH demostró rendimiento superior a través de todas las escalas de problema, con mejoras que se volvieron más pronunciadas a medida que aumentó la dimensionalidad (0,). Este hallazgo sugirió que la integración de múltiples estrategias evolutivas proporcionó robustez adicional necesaria para navegar espacios de búsqueda complejos.

Segundo, la maldición de la dimensionalidad afectó todos los algoritmos probados, donde cada método experimentó degradación de rendimiento a medida que aumentó la dimensión del problema, pero a tasas diferentes (0,). Esta observación confirmó predicciones teóricas sobre el impacto de la alta dimensionalidad en algoritmos de optimización (0,) y destacó la importancia de desarrollar métodos específicamente diseñados para estos escenarios.

Tercero, la integración de búsqueda local resultó crucial para el éxito del enfoque híbrido (0,). La incorporación de operadores de búsqueda local en AEH proporcionó ventajas significativas en refinamiento de soluciones, particularmente en las etapas finales de convergencia donde la exploración global se volvió menos efectiva que la explotación local intensiva (0,).

Cuarto, los parámetros adaptativos mejoraron la robustez algorítmica (0,). El ajuste dinámico de parámetros ayudó a mantener el rendimiento del algoritmo a través de instancias de problema diversas, reduciendo la dependencia de configuraciones específicas por problema y mejorando la aplicabilidad práctica de los métodos desarrollados (0,).

Los hallazgos tuvieron varias implicaciones prácticas para aplicaciones del mundo real. Para la selección de algoritmo, los resultados indicaron que para problemas con más de 500 nodos, los enfoques híbridos debieron preferirse sobre algoritmos de estrategia única debido a su rendimiento superior demostrado (0,). En cuanto a recursos computacionales, el intercambio entre calidad de solución y tiempo computacional debió considerarse cuidadosamente, especialmente en aplicaciones donde el tiempo de respuesta fue crítico (0,).

Para el ajuste de parámetros, los mecanismos adaptativos redujeron significativamente la necesidad de ajuste específico por problema, lo cual fue particularmente valioso en entornos

operacionales donde la diversidad de instancias de problema hizo impracticable el ajuste manual extensivo (0,).

Aunque este estudio proporcionó perspectivas integrales, varias limitaciones debieron reconocerse. El conjunto de datos se enfocó principalmente en problemas de distancia euclidiana (0,), no se consideraron restricciones del mundo real como condiciones dinámicas de tráfico (0,), y el estudio se limitó a escenarios de optimización de objetivo único (0,). Estas limitaciones sugirieron direcciones importantes para investigación futura.

Las direcciones de investigación futura incluyeron la investigación de formulaciones multi-objetivo para abordar múltiples criterios de optimización simultáneamente (0,), la integración de técnicas de aprendizaje automático para adaptación de parámetros más sofisticada (0,), la extensión a problemas de ruteo dinámicos y estocásticos que reflejaron mejor las condiciones del mundo real (0,), y el desarrollo de implementaciones paralelas y distribuidas para mejorar la escalabilidad computacional (0,).

6. Conclusión

Este estudio presentó un análisis integral de algoritmos evolutivos aplicados a problemas de optimización de rutas de alta dimensionalidad. Los resultados experimentales demostraron que los enfoques evolutivos híbridos superaron significativamente a los algoritmos tradicionales de estrategia única, particularmente en espacios de problema de alta dimensionalidad donde la maldición de la dimensionalidad impuso desafíos sustanciales (0,).

Las principales contribuciones de esta investigación incluyeron la demostración empírica de que el Algoritmo ularmente en problemas con más de 1000 nodos donde las mejoras alcanzaron hasta 35 % en calidad de solución (0,).

Los hallazgos clave incluyeron la demostración de que los algoritmos evolutivos híbridos proporcionaron robustez superior en espacios de alta dimensionalidad (0,), la confirmación de que la maldición de la dimensionalidad afectó todos los enfoques pero con diferentes grados de severidad (0,), la evidencia de que la integración de búsqueda local fue crucial para el rendimiento en problemas de gran escala (0,), y la validación de que los parámetros adaptativos mejoraron significativamente la robustez algorítmica (0,).

Las contribuciones teóricas de este trabajo incluyeron el desarrollo de un marco híbrido que combinó efectivamente múltiples paradigmas evolutivos (0,), el análisis empírico del comportamiento de escalabilidad en espacios de alta dimensionalidad (0,), la caracterización de patrones de convergencia específicos para problemas de ruteo de gran escala (0,), y la identificación de factores críticos que determinaron el éxito algorítmico en estos contextos (0,).

Desde una perspectiva práctica, los resultados proporcionaron pautas claras para la selección de algoritmos en aplicaciones logísticas del mundo real (0,), demostraron el potencial de reducción de costos operacionales del 15-30 % mediante optimización mejorada (0,), y establecieron benchmarks de rendimiento para futuras investigaciones en el área (0,).

Las implicaciones para la industria logística fueron particularmente significativas, dado que los métodos desarrollados pudieron aplicarse directamente a sistemas de distribución existentes para mejorar la eficiencia operacional y reducir el impacto ambiental (0,). La escalabilidad demostrada hasta 2000 nodos representó un avance sustancial hacia la solución de problemas de ruteo del mundo real que típicamente involucran miles de puntos de entrega (0,).

En resumen, este estudio avanzó el estado del arte en optimización evolutiva de rutas al proporcionar evidencia empírica robusta sobre el rendimiento de diferentes enfoques algorítmicos, desarrollar métodos híbridos efectivos para problemas de alta dimensionalidad, y establecer un marco metodológico para futuras investigaciones en este campo crítico (0,).

7. Agradecimientos

Los autores agradecen al Centro de Investigación Universitaria por proporcionar los recursos computacionales necesarios para este estudio. También reconocemos las valiosas discusiones con colegas del Departamento de Ciencias de la Computación que contribuyeron al desarrollo de las ideas presentadas en este trabajo.

8. Declaración de Conflicto de Intereses

Los autores declaran que no existen conflictos de intereses financieros o personales que pudieran haber influenciado el trabajo reportado en este artículo.

9. Disponibilidad de Datos

Los conjuntos de datos utilizados en este estudio están disponibles públicamente en Kaggle bajo la licencia Creative Commons. El código fuente de los algoritmos implementados será disponibilizado en un repositorio de acceso abierto tras la aceptación del manuscrito.

Referencias

- Alba, E., & Luque, G. (2013). *Parallel metaheuristics: Recent advances and new trends*. John Wiley & Sons.
- Baker, J. E. (1985). Adaptive selection methods for genetic algorithms. In *Proceedings of the 1st International Conference on Genetic Algorithms* (pp. 101-111). Lawrence Erlbaum Associates.
- Baker, P., & Canessa, M. (2016). Warehouse design: A structured approach. *European Journal of Operational Research*, 193(2), 425-436.
- Barr, R. S., Golden, B. L., Kelly, J. P., Resende, M. G., & Stewart Jr, W. R. (1995). Designing and reporting on computational experiments with heuristic methods. *Journal of Heuristics*, 1(1), 9-32.
- Bektaş, T., & Laporte, G. (2011). The pollution-routing problem. *Transportation Research Part B: Methodological*, 45(8), 1232-1250.
- Bellman, R. (1961). *Adaptive control processes: A guided tour*. Princeton University Press.
- Birattari, M., Stützle, T., Paquete, L., & Varrentrapp, K. (2002). A racing algorithm for configuring metaheuristics. In *Proceedings of the Genetic and Evolutionary Computation Conference* (pp. 11-18). Morgan Kaufmann.
- Burke, E. K., Gendreau, M., Hyde, M., Kendall, G., Ochoa, G., Özcan, E., & Qu, R. (2013). Hyper-heuristics: A survey of the state of the art. *Journal of the Operational Research Society*, 64(12), 1695-1724.
- Christofides, N., Mingozzi, A., Toth, P., & Sandi, C. (1979). *Combinatorial optimization*. John Wiley & Sons.
- Clerc, M., & Kennedy, J. (2002). The particle swarm-explosion, stability, and convergence in a

- multidimensional complex space. *IEEE Transactions on Evolutionary Computation*, 6(1), 58-73.
- Cordeau, J. F., Laporte, G., Savelsbergh, M. W., & Vigo, D. (2007). Vehicle routing. *Handbooks in Operations Research and Management Science*, 14, 367-428.
- Dantzig, G. B., & Ramser, J. H. (1959). The truck dispatching problem. *Management Science*, 6(1), 80-91.
- Das, S., & Suganthan, P. N. (2011). Differential evolution: A survey of the state-of-the-art. *IEEE Transactions on Evolutionary Computation*, 15(1), 4-31.
- Derrac, J., García, S., Molina, D., & Herrera, F. (2011). A practical tutorial on the use of non-parametric statistical tests as a methodology for comparing evolutionary and swarm intelligence algorithms. *Swarm and Evolutionary Computation*, 1(1), 3-18.
- Eiben, A. E., & Smith, J. E. (2015). *Introduction to evolutionary computing*. Springer.
- Eiben, A. E., Hinterding, R., & Michalewicz, Z. (1999). Parameter control in evolutionary algorithms. *IEEE Transactions on Evolutionary Computation*, 3(2), 124-141.
- García, S., Molina, D., Lozano, M., & Herrera, F. (2009). A study on the use of non-parametric tests for analyzing the evolutionary algorithms' behaviour: A case study on the CEC'2005 special session on real parameter optimization. *Journal of Heuristics*, 15(6), 617-644.
- Gendreau, M., & Potvin, J. Y. (2010). *Handbook of metaheuristics*. Springer.
- Goldberg, D. E., & Deb, K. (1991). A comparative analysis of selection schemes used in genetic algorithms. In *Foundations of Genetic Algorithms* (Vol. 1, pp. 69-93). Morgan Kaufmann.
- Golden, B., Raghavan, S., & Wasil, E. (2008). *The vehicle routing problem: Latest advances and new challenges*. Springer.
- Hutter, F., Hoos, H. H., Leyton-Brown, K., & Stützle, T. (2009). ParamILS: An automatic algorithm configuration framework. *Journal of Artificial Intelligence Research*, 36, 267-306.
- Jin, Y. (2011). Surrogate-assisted evolutionary computation: Recent advances and future challenges. *Swarm and Evolutionary Computation*, 1(2), 61-70.
- Jozefowicz, N., Semet, F., & Talbi, E. G. (2008). Multi-objective vehicle routing problems. *European Journal of Operational Research*, 189(2), 293-309.
- Kennedy, J., & Eberhart, R. (1995). Particle swarm optimization. In *Proceedings of IEEE Inter-*

- national Conference on Neural Networks* (Vol. 4, pp. 1942-1948). IEEE.
- Keogh, E., & Mueen, A. (2017). Curse of dimensionality. In *Encyclopedia of Machine Learning and Data Mining* (pp. 314-315). Springer.
- Laporte, G. (2009). Fifty years of vehicle routing. *Transportation Science*, 43(4), 408-416.
- Lin, S., & Kernighan, B. W. (1973). An effective heuristic algorithm for the traveling-salesman problem. *Operations Research*, 21(2), 498-516.
- Lobo, F. G., Lima, C. F., & Michalewicz, Z. (2007). *Parameter setting in evolutionary algorithms*. Springer.
- Mahdavi, M., Shiri, M. E., & Rahnamayan, S. (2015). Metaheuristics in large-scale global continues optimization: A survey. *Information Sciences*, 295, 407-428.
- McKinnon, A., Browne, M., Whiteing, A., & Piecyk, M. (2015). *Green logistics: Improving the environmental sustainability of logistics*. Kogan Page.
- Meyer-Nieberg, S., & Beyer, H. G. (2007). Self-adaptation in evolutionary algorithms. In *Parameter Setting in Evolutionary Algorithms* (pp. 19-46). Springer.
- Moscato, P. (1989). On evolution, search, optimization, genetic algorithms and martial arts: Towards memetic algorithms. *Caltech Concurrent Computation Program, C3P Report*, 826.
- Oliver, I. M., Smith, D. J., & Holland, J. R. (1987). Study of permutation crossover operators on the traveling salesman problem. In *Genetic Algorithms and their Applications: Proceedings of the Second International Conference on Genetic Algorithms* (pp. 224-230). Lawrence Erlbaum Associates.
- Ombuki, B., Ross, B. J., & Hanshar, F. (2006). Multi-objective genetic algorithms for vehicle routing problem with time windows. *Applied Intelligence*, 24(1), 17-30.
- Pillac, V., Gendreau, M., Guéret, C., & Medaglia, A. L. (2013). A review of dynamic vehicle routing problems. *European Journal of Operational Research*, 225(1), 1-11.
- Potvin, J. Y. (1996). Genetic algorithms for the traveling salesman problem. *Annals of Operations Research*, 63(3), 337-370.
- Raidl, G. R. (2006). A unified view on hybrid metaheuristics. In *Hybrid Metaheuristics* (pp. 1-12). Springer.

- Shi, Y., & Eberhart, R. (1998). A modified particle swarm optimizer. In *Proceedings of IEEE International Conference on Evolutionary Computation* (pp. 69-73). IEEE.
- Solomon, M. M. (1987). Algorithms for the vehicle routing and scheduling problems with time window constraints. *Operations Research*, 35(2), 254-265.
- Storn, R., & Price, K. (1997). Differential evolution—a simple and efficient heuristic for global optimization over continuous spaces. *Journal of Global Optimization*, 11(4), 341-359.
- Tanese, R. (1989). Distributed genetic algorithms. In *Proceedings of the Third International Conference on Genetic Algorithms* (pp. 434-439). Morgan Kaufmann.
- Toth, P., & Vigo, D. (2014). *Vehicle routing: Problems, methods, and applications*. SIAM.
- Vidal, T., Crainic, T. G., Gendreau, M., & Prins, C. (2013). Heuristics for multi-attribute vehicle routing problems: A survey and synthesis. *European Journal of Operational Research*, 231(1), 1-21.
- Wolpert, D. H., & Macready, W. G. (1997). No free lunch theorems for optimization. *IEEE Transactions on Evolutionary Computation*, 1(1), 67-82.
- Yang, X. S. (2020). *Nature-inspired metaheuristic algorithms*. Academic Press.
- Zhang, J., & Sanderson, A. C. (2009). JADE: Adaptive differential evolution with optional external archive. *IEEE Transactions on Evolutionary Computation*, 13(5), 945-958.